

Отчет по результатам выполнения заданий практикума

Студент: Миляев А.Б. 316

10 декабря 2025 г.

Содержание

1	Описание датасета, краткие характеристики (максимумы, минимумы, средние значения, пропуски и т.п.)	4
2	Аппроксимация распределений данных с помощью ядерных оценок	5
3	Анализ данных с помощью <code>cdplot</code>, <code>dotchart</code>, <code>boxplot</code> и <code>stripchart</code>	6
3.1	<code>cdplot</code>	6
3.2	<code>Dotchart</code>	7
3.3	<code>Boxplot</code>	8
3.4	<code>Stripchart</code>	9
4	Выявление выбросов с точки зрения формальных статистических критериев Граббса и Q-теста Диксона	10
4.1	Критерий Граббса	10
4.2	Q-тест Диксона	10
5	Воспользоваться инструментами для заполнения пропусков в данных. Пропуски внести вручную и сравнить результаты заполнения с истинными значениями	12
6	Анализ нормального распределения (на малых и больших выборках)	13
6.1	Анализ с помощью графиков эмпирических функций распределений	13
6.2	Анализ с помощью графиков квантилей	15
6.3	Анализ с помощью графиков метода огибающих	16
6.4	Стандартные процедуры проверки гипотез о нормальности	17
6.4.1	Критерий Колмогорова-Смирнова	17
6.4.2	Критерий Шапиро-Уилка	17
6.4.3	Критерий Андерсона-Дарлинга	18
6.4.4	Критерий Крамера фон Мизеса	18
6.4.5	Критерий Колмогорова-Смирнова в модификации Лиллиефорса	19
6.4.6	Критерий Шапиро-Франсия	19
7	Продemonстрировать пример анализа данных с помощью графиков квантилей, метода огибающих, а также стандартных процедур проверки гипотез о нормальности. Рассмотреть выборки малого и умеренного объемов	20
7.1	Анализ данных с помощью графиков квантилей	20
7.2	Анализ с помощью метода огибающих	21
7.3	Стандартные процедуры проверки гипотез о нормальности	22
7.3.1	Критерий Колмогорова-Смирнова	22
7.3.2	Критерий Шапиро-Уилка	22
7.3.3	Критерий Андерсона-Дарлинга	22
7.3.4	Критерий Крамера фон Мизеса	22
7.3.5	Критерий Колмогорова-Смирнова в модификации Лиллиефорса и ШапироФрансия	22
7.3.6	Критерий Шапиро-Франсия	22
8	Продemonстрировать применение для проверки различных гипотез и различных доверительных уровней (0.9, 0.95, 0.99) некоторых критериев	23
8.1	Одновыборочный критерий Стьюдента	23
8.1.1	Двусторонний критерий Стьюдента	23
8.1.2	Односторонние критерии Стьюдента. Greater	23
8.1.3	Односторонние критерии Стьюдента. Less	24
8.2	Двухвыборочный критерий Стьюдента	25
8.2.1	Доверительный уровень 0.9	25
8.2.2	Доверительный уровень 0.95	25
8.2.3	Доверительный уровень 0.99	25
8.3	Ранговый критерий Уилкоксона-Манна-Уитни	27
8.4	Проверка гипотез об однородности дисперсий	27
8.4.1	Критерий Фишера	27
8.4.2	Критерий Левене	27
8.4.3	Критерий Бартлетта	28
8.4.4	Критерий Флигнера-Килина	28

9	Исследовать корреляционные взаимосвязи в данных с помощью коэффициентов корреляции Пирсона, Спирмена и Кендалла.	29
9.1	Коэффициент корреляции Пирсона	29
9.2	Коэффициент корреляции Спирмена	29
9.3	Коэффициент корреляции Кендалла	29
10	Продемонстрировать использование методов хи-квадрат, точного теста Фишера, теста МакНемара, КохранаМантеля-Хензеля.	30
10.1	Метод хи-квадрат	30
10.2	Точный тест Фишера	31
10.3	Тест МакНемара	31
10.4	Тест Кохрана-Мантеля-Хензеля	32
11	Проверить наличие мультиколлинеарности в данных с помощью корреляционной матрицы и фактора инфляции дисперсии.	33
11.1	Корреляционная матрица	33
11.2	Фактор инфляции дисперсии	34
12	Исследовать зависимости в данных с помощью дисперсионного анализа.	35
12.1	Однофакторный дисперсионный анализ (one-way ANOVA)	35
12.2	Двухфакторный дисперсионный анализ (two-way ANOVA)	35
13	Подогнать регрессионные модели (в том числе, нелинейные) к данным, а также оценить качество подобной аппроксимации.	36
14	Выводы	37
15	Литература	38

1 Описание датасета, краткие характеристики (максимумы, минимумы, средние значения, пропуски и т.п.)

Анализируемый датасет содержит информацию о 1000 пациентов. Описание столбцов:

1. **Patient_ID**: уникальный анонимный идентификатор пациента
2. **Respiratory_Rate**: количество вдохов в минуту
3. **Oxygen_Saturation**: уровень насыщенности крови кислородом (
4. **O2_Scale**: шкала используемости кислородной терапии
5. **Systolic_BP**: систолическое артериальное давление (мм рт ст)
6. **Heart_Rate**: пульс в минуту
7. **Temperature**: температура тела (°C)
8. **Consciousness**: уровень сознания (A = тревога, P = реакция на боль, C = замешательство, V = вербальный, U = не реагирует)
9. **On_Oxygen**: получает ли пациент дополнительный кислород (0 = нет, 1 = да)
10. **Risk_Level**: целевая переменная (нормальный, низкий, средний, высокий)


Таблица 1: Статистические характеристики данных

Параметр	Count	Mean	Std	Min	25%	50%	75%	Max
Heart Rate Variability	1000	70.39	19.58	5.17	57.05	70.51	82.96	147.05
Body Temperature	1000	36.54	0.50	35.03	36.20	36.53	36.86	38.10
Movement During Sleep	1000	2.01	0.98	-1.02	1.35	2.00	2.66	5.93
Sleep Duration Hours	1000	7.47	1.54	3.11	6.39	7.50	8.50	12.36
Sleep Quality Score	1000	2.59	2.98	1.00	1.00	1.00	2.54	10.00
Caffeine Intake Mg	1000	148.26	94.03	0.00	80.63	145.72	211.24	400.00
Stress Level	1000	4.94	2.03	0.00	3.49	4.89	6.40	10.00
Bedtime Consistency	1000	0.50	0.20	0.00	0.36	0.50	0.64	1.00
Light Exposure Hours	1000	8.04	2.02	0.33	6.73	8.04	9.35	14.75

В данных нет пропусков.

2 Аппроксимация распределений данных с помощью ядерных оценок

Ядерная оценка плотности (Kernel Density Estimation, KDE) — это метод оценки вероятностной плотности случайной величины. Этот метод позволяет аппроксимировать неизвестную функцию плотности распределения по выборке данных. Визуально KDE позволяет сгладить данные и создать непрерывную кривую, которая описывает, как распределены наблюдения.




Выводы

Можем, например, сделать вывод о схожести распределений расных признаков: Respiratory_Rate и Heart_Rate, а также Oxygen_Saturation и Systolic_BP

3 Анализ данных с помощью cdfplot, dotchart, boxplot и stripchart

3.1 cdfplot


cdfplot (Conditional Density Plot) — это график условной плотности, который показывает распределение одной непрерывной переменной в зависимости от другой категориальной переменной. График помогает визуализировать, как распределение непрерывной переменной изменяется в зависимости от различных категорий.



Выводы Можем увидеть, что при Respiratory_Rate > 26 Risk_Level почти полностью имеет значение High. При Respiratory_Rate от 23 до 26 преобладает Medium. При Respiratory_Rate от 12 до 17 преобладает Normal, а далее Low

3.2 Dotchart

Dotchart (точечная диаграмма) — это вид графика, который отображает значения данных с помощью точек. Точечные диаграммы используются для визуализации числовых данных и сравнений между несколькими категориями. Этот тип графика похож на столбчатую диаграмму, но вместо столбцов используются точки для отображения значений.




Вывод:

Видим, что при высоких значениях пульса, температуры и количества вдохов риск высок. Аналогично при малых значениях артериального давления и уровня насыщенности крови кислородом

3.3 Boxplot


Boxplot (“ящик с усами”) — это графический метод визуализации числовых данных, который отображает пять основных статистических показателей: минимальное значение, первый квартиль (Q1), медиану (Q2), третий квартиль (Q3), и максимальное значение. Это мощный инструмент для выявления распределения данных, межквартильного размаха и наличия выбросов.



Выводы Можем сделать выводы, аналогичные Dotchart про высокий риск. Дополнительно можем рассмотреть выбросы в разных местах

3.4 Stripchart

Stripchart — это график, который отображает распределение данных, представляя каждое отдельное наблюдение в виде точки на оси. Он полезен для визуализации небольших наборов данных и позволяет увидеть каждое уникальное значение в одном ряду.



Выводы Можем увидеть, что в температуре высокий риск размазан по всем значениям, а средний, низкий и нормальный более кучкуются. Аналогично и в остальных параметрах

4 Выявление выбросов с точки зрения формальных статистических критериев Граббса и Q-теста Диксона

Для этих критериев требуется нормальность выборки. В пункте 7 будет показано, что в моем датасете нет нормально распределенных данных, поэтому сгенерирую данные из нормального распределения с параметрами (0, 1)


4.1 Критерий Граббса

Критерий Граббса — статистический тест, используемый для определения выбросов в одномерном наборе данных, подчиняющихся нормальному закону распределения. Статистика G для поиска максимального выброса вычисляется следующим образом:

$$G = \frac{X_{max} - \bar{X}}{s}$$

где X_{max} — максимальное значение, которое мы проверяем на принадлежность выбросам, $\bar{X}$ — среднее выборки, s — стандартное отклонение выборки. Если G достигает критического значения из таблицы Граббса для конкретного уровня значимости, то X_{max} — это действительно выброс. Аналогично формулируется критерий Граббса для минимума.

Получил, что значение 3.6379 является выбросом



4.2 Q-тест Диксона

Для теста Диксона существуют ограничения: он может корректно анализировать только малые выборки данных (от 3 до 20). По критерию Граббса мы знаем, что выброс находится на 895 позиции датасета, поэтому ограничим поиск выброса на позициях от 890 до 909.

Для проведения q-теста Диксона необходимо отсортировать массив значений по возрастанию и посчитать число Q по формуле:

Статистика Q рассчитывается по формуле:

$$Q = \frac{|potential\ outlier - nearest\ neighbor|}{maximum\ value - minimum\ value}$$

Далее необходимо сравнить полученное Q с критическим значением из таблицы Qtable, соответствующее количеству значений в выборке на определенном уровне значимости. Если $Q > Q_{table}$, то potential outlier действительно является выбросом.

Dixon test for outliers

data: data

Q = 0.29678, p-value = 0.3205

alternative hypothesis: highest value 2.55005802800941 is an outlier


5 Воспользоваться инструментами для заполнения пропусков в данных. Пропуски внести вручную и сравнить результаты заполнения с истинными значениями

Заполнение пропусков в данных — это важный этап в анализе данных, необходимым для обеспечения корректности анализа и работы моделей. Пропуски могут:

1. Искажать результаты статистических расчетов.
2. Нарушать работу алгоритмов машинного обучения, которые требуют полных данных.
3. Уменьшать объем доступной информации, если строки с пропусками удаляются.

В моем датасете пропусков нет, поэтому создам их искусственно: в колонке `Heart_Rate` элементы с 0 по 10 будут `None`.

Для заполнения пропусков я воспользовался встроенной моделью заполнения пропусков, которая восстанавливает значения по другим признакам



Можем увидеть (на графиках изображены первые 10 элементов `Heart_Rate`), что модель восстановила данные достаточно точно (гораздо лучше, чем заполнение средним или медианой, которое бы просто выглядело как один столбец)

6 Анализ нормального распределения (на малых и больших выборках)

Для выполнения данного пункта было сгенерировано пять выборок из нормального распределения со следующими параметрами:

1. *data_1*: математическое ожидание $\mu_1 = 0$, среднеквадратическое отклонение $\sigma_1 = 1$, количество элементов в выборке $n_1 = 2000$
2. *data_2*: математическое ожидание $\mu_2 = 0$, среднеквадратическое отклонение $\sigma_1 = 3$, количество элементов в выборке $n_2 = 2000$
3. *data_3*: математическое ожидание $\mu_1 = 1$, среднеквадратическое отклонение $\sigma_1 = 4$, количество элементов в выборке $n_3 = 2000$
4. *data_4*: математическое ожидание $\mu_1 = 5$, среднеквадратическое отклонение $\sigma_1 = 8$, количество элементов в выборке $n_4 = 75$
5. *data_5*: математическое ожидание $\mu_1 = 9$, среднеквадратическое отклонение $\sigma_1 = 2$, количество элементов в выборке $n_5 = 75$

6.1 Анализ с помощью графиков эмпирических функций распределений

Эмпирическая функция распределения (выборочная функция распределения) — естественное приближение теоретической функции распределения данной случайной величины, построенное по выборке. Пусть задана случайная выборка $x^m = (x_1, \dots, x_m)$ наблюдений $x_i \in X$. Построим по выборке ступенчатую функцию $\hat{F}_m(x)$, возрастающую скачками величины $\frac{1}{m}$ в точках $x_{(i)}$. Построенная функция называется эмпирической функцией распределения. Для задания значений в точках разрыва формально определим её так:

$$\hat{F}_m = \frac{1}{m} \sum_{i=1}^m I\{x_i \leq x\}$$

Замечание: при этом эмпирическая функция непрерывна справа.

Свойства эмпирической функции распределения

1. Эмпирическое распределение для фиксированного x

Поскольку случайная величина $I\{x_i \leq x\}$ имеет распределение Бернулли с вероятностью успеха $F(x)$ (где $F(x)$ — **теоретическая функция** распределения случайной величины x), а последовательность $(I\{x_1 \leq x\}, \dots, I\{x_m \leq x\})$ — схема Бернулли с вероятностью успеха $F(x)$, то по отношению к этой последовательности $\hat{F}_m(x)$ есть частота попаданий левее x .

Из сказанного вытекает, что эмпирическое распределение служит естественным приближением к теоретической функции распределения.

2. Математическое ожидание и дисперсия эмпирического распределения

Математическое ожидание эмпирической функции распределения:

$$E(|\hat{F}_m(x)|) = F(x)$$

таким образом, эмпирическое распределение является **несмещённой оценкой** теоретической функции распределения $F(x)$.

Дисперсия эмпирического распределения:

$$D(|\hat{F}_m(x)|) = \frac{(1 - F(x))F(x)}{m}$$


3. Асимптотические свойства эмпирической функции распределения

- (а) По **усиленному закону больших чисел** $\hat{F}_m(x)$ сходится **почти наверное** к теоретической функции распределения $F(x)$:

$$\hat{F}_m(x) \rightarrow F(x) \quad m \rightarrow \infty$$

- (б) Выборочная функция распределения является **асимптотически нормальной** оценкой функции распределения $F(x)$, при условии, что $0 < F(x) < 1, \forall x \in R$:

$$\sqrt{m}(\hat{F}_m(x)F(x))PN(0, F(x)(1F(x))) \quad m \rightarrow \infty$$




Общие выводы

На основании представленных графиков эмпирических функций распределения и параметров распределений можно сделать следующие выводы:

- Эмпирические функции распределения хорошо согласуются с теоретическими функциями нормального распределения, что подтверждает нормальный характер данных
- Различия в параметрах (математическое ожидание, среднее квадратическое отклонение, количество элементов в выборке) влияют на форму и положение эмпирической ФР.

6.2 Анализ с помощью графиков квантилей

График квантилей (QQ plot) используется для сравнения распределения данных с теоретическим распределением или с другим набором данных. На осях координат нанесены квантили выборки и квантили теоретического распределения (или другой выборки). Если точки лежат близко к диагональной прямой, распределение выборки соответствует теоретическому.




Общие выводы

1. На графиках для выборок малого объема (`data_4`, `data_5`) отклонения от теоретической линии более заметны, особенно в хвостах, из-за меньшего числа наблюдений и большей чувствительности к случайному шуму.
2. Графики квантилей для выборок большого объема (`data_1`, `data_2`, `data_3`) демонстрируют почти идеальное соответствие теоретическому нормальному распределению, так как больший объем данных сглаживает влияние шума и случайных отклонений.
3. Графики Q-Q подтверждают нормальный характер всех распределений, с минимальными отклонениями в зависимости от объема и параметров выборок.

6.3 Анализ с помощью графиков метода огибающих

Метод огибающих (envelope method) — это статистический метод, используемый для оценки и визуализации соответствия эмпирических данных теоретической модели. Метод огибающих создает области или доверительные интервалы (огибающие) вокруг ожидаемой теоретической зависимости, чтобы учитывать вариации данных. Эти области помогают определить, насколько данные соответствуют теоретической модели, либо служат для анализа ключевых направлений в данных



Общие выводы

1. Выборки малого объема (data_4 и data_5) показывают значительные отклонения от огибающей, что объясняется случайностью данных и недостаточным количеством наблюдений.
2. Выборки большого объема (data_1, data_2, data_3) демонстрируют гораздо лучшее соответствие данным с огибающей, что подтверждает более точное моделирование и уменьшение случайных отклонений, позволяя делать более надежные выводы.
3. С увеличением объема выборки точность метода огибающих возрастает, поэтому результаты становятся более стабильными.

6.4 Стандартные процедуры проверки гипотез о нормальности

6.4.1 Критерий Колмогорова-Смирнова

Классический критерий Колмогорова (иногда говорят Колмогорова-Смирнова) предназначен для проверки простых гипотез о принадлежности анализируемой выборки некоторому полностью известному закону распределения

Пусть X_n — выборка независимых одинаково распределённых случайных величин, $F_n(x)$ — эмпирическая функция распределения, $F(x)$ — некоторая «истинная» функция распределения с известными параметрами. Статистика критерия определяется выражением:

$$D_n = \sup_x |F_n(x) - F(x)|$$

Обозначим через H_0 гипотезу о том, что выборка подчиняется распределению $F(x) \in C^1(x)$. Тогда по теореме Колмогорова при справедливости проверяемой гипотезы:

$$\forall t > 0 : \lim_{n \rightarrow \infty} P(\sqrt{n}D_n \leq t) = K(t) = \sum_{j=-\infty}^{+\infty} (-1)^j \exp(-2j^2 t^2)$$

Гипотеза H_0 отвергается, если статистика $\sqrt{n}D_n$ превышает квантиль распределения K_α заданного уровня значимости α , и принимается в противном случае.

Результаты:

1. data_1 KstestResult(statistic=0.016072, pvalue=0.673594)
2. data_2 KstestResult(statistic=0.024443, pvalue=0.180172)
3. data_3 KstestResult(statistic=0.027642, pvalue=0.092375)
4. data_4 KstestResult(statistic=0.078056, pvalue=0.720996)
5. data_5 KstestResult(statistic=0.096661, pvalue=0.456734)

Выводы

Для всех выборок p-value > 0.05, поэтому гипотеза о нормальности не отвергается.

6.4.2 Критерий Шапиро-Уилка

Критерий Шапиро-Уилка используется для проверки гипотезы H_0 : «случайная величина X распределена нормально» и является одним из наиболее эффективных критериев проверки нормальности. Критерии, проверяющие нормальность выборки, являются частным случаем критериев согласия.

Критерий Шапиро-Уилка основан на оптимальной линейной несмещённой оценке дисперсии к её обычной оценке методом максимального правдоподобия. Статистика критерия имеет вид:

$$W = \frac{s}{2} \left[\sum_{i=1}^n a_{n-i+1} (x_{n-i+1} - x_i) \right]^2$$

где

$$s^2 = \sum_{i=1}^n (x_i - \bar{x})^2, \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Числитель является квадратом оценки среднеквадратического отклонения Ллойда. Коэффициенты a_{n-i+1} берутся из специальных таблиц

Результаты:

1. data_1 ShapiroResult(statistic=0.999499, pvalue=0.907326)
2. data_2 ShapiroResult(statistic=0.999355, pvalue=0.751856)
3. data_3 ShapiroResult(statistic=0.999591, pvalue=0.967273)
4. data_4 ShapiroResult(statistic=0.981632, pvalue=0.348055)
5. data_5 ShapiroResult(statistic=0.986692, pvalue=0.622858)

Выводы

Для всех выборок $p\text{-value} > 0.05$, поэтому гипотеза о нормальности не отвергается.

6.4.3 Критерий Андерсона-Дарлинга

Классический непараметрический **критерий согласия Андерсона — Дарлинга** предназначен для проверки простых гипотез о принадлежности анализируемой выборки полностью известному закону (о согласии эмпирического распределения $F_n(x)$ и теоретического закона $F(x, \theta)$), то есть для проверки гипотез вида:

$$H_0 : F_n(x) = F(x, \theta)$$

с известным вектором параметров теоретического закона.

В критерии Ω^2 Андерсона — Дарлинга используется статистика вида:

$$S_\Omega = -n - 2 \sum_{i=1}^n \left\{ \frac{2i-1}{2n} \ln(F(x_i, \theta)) + \left(1 - \frac{2i-1}{2n}\right) \ln(1 - F(x_i, \theta)) \right\}$$

где n — объём выборки, $x_1, x_2, \dots, x_n$ — упорядоченные по возрастанию элементы выборки.

Результаты:

1. data_1 AndersonResult(statistic=0.168421, p-value > 0.05)
2. data_2 AndersonResult(statistic=0.227026, p-value > 0.05)
3. data_3 AndersonResult(statistic=0.256777, p-value > 0.05)
4. data_4 AndersonResult(statistic=0.517445, p-value > 0.05)
5. data_5 AndersonResult(statistic=0.322188, p-value > 0.05)

Выводы

Для всех выборок $p\text{-value} > 0.05$, поэтому гипотеза о нормальности не отвергается

6.4.4 Критерий Крамера фон Мизеса

Критерий Крамера-фон-Мизеса используется для проверки гипотезы «случайная величина X имеет распределение $F(x)$ ». Пусть $x_1, \dots, x_n$ — элементы выборки, упорядоченные по возрастанию. Статистика критерия имеет вид

$$n\omega^2 = \frac{1}{12n} + \sum_{i=1}^n \left(F(x_i) - \frac{2i-1}{2n} \right)^2$$

где $F(x)$ — теоретическая функция распределения с известными параметрами. То есть, проверяется простая гипотеза.

При объёме выборки $n > 40$ можно пользоваться квантилями распределения $n\omega^2$, приведенными в следующей таблице:

α	0.900	0.950	0.990	0.995	0.999
$n\omega_n^2(\alpha)$	0.3473	0.4614	0.7435	0.8694	1.1679

Результаты:

1. data_1 CramerVonMisesResult(statistic=0.042173, pvalue=0.921684)
2. data_2 CramerVonMisesResult(statistic=0.031671, pvalue=0.970394)
3. data_3 CramerVonMisesResult(statistic=0.104565, pvalue=0.562996)
4. data_4 CramerVonMisesResult(statistic=0.157149, pvalue=0.369125)
5. data_5 CramerVonMisesResult(statistic=0.053752, pvalue=0.854661)

Выводы

Все $p\text{-value} > 0.05$, что указывает на то, что гипотеза о нормальности распределения данных не отклоняется для всех выборок.

6.4.5 Критерий Колмогорова-Смирнова в модификации Лиллиефорса

Критерий Лиллиефорса является модификацией критерия Колмогорова-Смирнова и используется для проверки нулевой гипотезы о том, что выборка распределена по нормальному закону для случая, когда параметры нормального распределения (математическое ожидание и дисперсия) априори неизвестны.

Результаты:

1. data_1: статистика $D = 0.010629$, p-value = 0.855009
2. data_1: статистика $D = 0.013233$, p-value = 0.554712
3. data_1: статистика $D = 0.013532$, p-value = 0.517401
4. data_1: статистика $D = 0.098101$, p-value = 0.099473
5. data_1: статистика $D = 0.068193$, p-value = 0.590861

Выводы

Все p-value > 0.05 , что указывает на то, что гипотеза о нормальности распределения данных не отклоняется для всех выборок.

6.4.6 Критерий Шапиро-Франсия

Критерий Шапиро-Франсия используется для проверки гипотезы H_0 : «случайная величина X распределена нормально». Введен в 1972 году как упрощение теста Шапиро-Уилка.

Пусть $x_{(i)}$ — это i -й порядковый элемент из выборки объема n . Пусть $m_{i:n}$ — это среднее значение i -го порядкового статистического значения при совершении n независимых выборок из нормального распределения.

Теперь формируем коэффициент корреляции Пирсона между выборочными значениями x и теоретическими значениями m :

$$W' = \frac{cov(x, m)}{\sigma_x \sigma_m} = \frac{\sum_{i=1}^n (x_{(i)} - \bar{x})(m_i - \bar{m})}{\sqrt{(\sum_{i=1}^n (x_{(i)} - \bar{x})^2) (\sum_{i=1}^n (m_i - \bar{m})^2)}}$$

При нулевой гипотезе, что данные взяты из нормального распределения, эта корреляция будет сильной, и значения W будут сгруппированы около 1, при этом пик будет становиться уже и приближаться к 1 с увеличением n . Если данные сильно отклоняются от нормального распределения, то W будет меньше.

Этот тест является формализацией более старой практики построения графика Q-Q для сравнения двух распределений, где x выполняет роль квантилей эмпирического распределения, а m — роль соответствующих квантилей нормального распределения.

В отличие от статистики теста Шапиро-Уилка W , статистика теста Шапиро-Франсия W легче вычисляется, поскольку не требует формирования и инверсии матрицы ковариаций между порядковыми статистиками.

Результаты:

1. data_1: статистика $W = 0.999639$, p-value = 0.970849
2. data_2: статистика $W = 0.999292$, p-value = 0.611425
3. data_3: статистика $W = 0.999557$, p-value = 0.919634
4. data_4: статистика $W = 0.983603$, p-value = 0.374169
5. data_5: статистика $W = 0.989194$, p-value = 0.687291


Выводы

Все p-value > 0.05 , что указывает на то, что гипотеза о нормальности распределения данных не отклоняется для всех выборок.

7 Продemonстрировать пример анализа данных с помощью графиков квантилей, метода огибающих, а также стандартных процедур проверки гипотез о нормальности. Рассмотреть выборки малого и умеренного объемов

Для анализа выборки умеренного объема я возьму колонку `Heart_Rate`, а для выборки малого объема эту же колонку, но элементы с 50 по 100



7.1 Анализ данных с помощью графиков квантилей



Выводы

QQ-plot на большой выборке показывает сильные отклонения от прямой линии, что указывает на то, что данные не являются нормальными. На малой выборке QQ-plot ближе к прямой линии

7.2 Анализ с помощью метода огибающих



Выводы Выборка большого объема показывает значительные отклонения от огибающей, что доказывает отсутствие нормальности данных. Выборка маленького объема демонстрирует гораздо лучшее соответствие данных с огибающей.

7.3 Стандартные процедуры проверки гипотез о нормальности

7.3.1 Критерий Колмогорова-Смирнова

1. data_1 KstestResult(statistic=0.082665, pvalue=2.156505e-06)
2. data_2 KstestResult(statistic=0.082069, pvalue=0.861844)

7.3.2 Критерий Критерий Шапиро-Уилка

1. data_1 ShapiroResult(statistic=0.961415, pvalue=1.344612e-15)
2. data_2 ShapiroResult(statistic=0.970959, pvalue=0.253092)

7.3.3 Критерий Андерсона-Дарлинга

1. data_1 AndersonResult(statistic=10.921159, p-value < 0.05)
2. data_2 AndersonResult(statistic=0.439289, p-value > 0.05)

7.3.4 Критерий Крамера фон Мизеса

1. data_1 CramerVonMisesResult(statistic=1.752301, pvalue=4.569592e-05)
2. data_2 CramerVonMisesResult(statistic=0.062526, pvalue=0.800351)

7.3.5 Критерий Колмогорова-Смирнова в модификации Лиллиефорса и ШапироФрансия

1. data_1 статистика $D = 0.082691$, p-value = 0.000999
2. data_2 статистика $D = 0.079625$, p-value = 0.587707

7.3.6 Критерий Шапиро-Франсия

1. data_1 статистика $W = 0.962032$, p-value = 5.930052e-14
2. data_2 статистика $W = 0.974692$, p-value = 0.300557

Выводы

Выборка малого объема распределена нормально, большого нет

8 Продemonстрировать применение для проверки различных гипотез и различных доверительных уровней (0.9, 0.95, 0.99) некоторых критериев

8.1 Одновыборочный критерий Стьюдента

Пусть дана выборка $x_n = (x_1, \dots, x_n), x_i \in R$,

Обозначим через μ и σ^2 математическое ожидание и дисперсию выборки соответственно.

Дополнительное предположение: выборка x_n является нормальной

Нулевая гипотеза $H_0 : \mu = \mu_0$, где μ_0 - некоторое заданное число.

Возможные альтернативные гипотезы:

1. $H_1 : \mu \neq \mu_0$ (two-sided)
2. $H'_1 : \mu > \mu_0$ (greater)
3. $H''_1 : \mu < \mu_0$ (less)

Так как критерий требует нормальности, а в моем датасете нормально распределенных колонок нет, сгенерируем данные вручную

1. *data_1*: математическое ожидание $\mu_1 = 0$, среднеквадратическое отклонение $\sigma_1 = 3$, количество элементов в выборке $n_1 = 100$
2. *data_2*: математическое ожидание $\mu_2 = 1$, среднеквадратическое отклонение $\sigma_1 = 3$, количество элементов в выборке $n_2 = 300$

Проверим на разных уровнях доверия на значение 1 для *data_2*: $\alpha = 0.90$, $\alpha = 0.95$, $\alpha = 0.99$

8.1.1 Двусторонний критерий Стьюдента

	T	dof	alternative	p-val	CI90%	cohen-d	BF10	power
T-test	0.464268	299	two-sided	0.642794	[0.7887, 1.3767]	0.026804	0.072	0.074874

	T	dof	alternative	p-val	CI95%	cohen-d	BF10	power
T-test	0.464268	299	two-sided	0.642794	[0.73, 1.43]	0.026804	0.072	0.074874

	T	dof	alternative	p-val	CI99%	cohen-d	BF10	power
T-test	0.464268	299	two-sided	0.642794	[0.6208, 1.5446]	0.026804	0.072	0.074874

8.1.2 Односторонние критерии Стьюдента. Greater

	T	dof	alternative	p-val	CI95%	cohen-d	BF10	power
T-test	-3.884211	99	greater	0.999907	[-0.6149, ∞]	0.388421	0.005	1.868×10^{-8}

	T	dof	alternative	p-val	CI95%	cohen-d	BF10	power
T-test	0.464268	299	greater	0.321397	[0.79, ∞]	0.026804	0.144	0.118675

	T	dof	alternative	p-val	CI99%	cohen-d	BF10	power
T-test	0.464268	299	greater	0.321397	[0.6660, ∞]	0.026804	0.144	0.118675

8.1.3 Односторонние критерии Стьюдента. Less

	T	dof	alternative	p-val	CI90%	cohen-d	BF10	power
T-test	0.464268	299	less	0.678603	$(-\infty, 1.311579]$	0.026804	0.144	0.017512

	T	dof	alternative	p-val	CI95%	cohen-d	BF10	power
T-test	0.464268	299	less	0.678603	$(-\infty, 1.38]$	0.026804	0.144	0.017512

	T	dof	alternative	p-val	CI99%	cohen-d	BF10	power
T-test	0.464268	299	less	0.678603	$(-\infty, 1.499472]$	0.026804	0.144	0.017512

По значениям можем сделать вывод, что среднее как раз 1

8.2 Двухвыборочный критерий Стьюдента

Пусть даны две независимые выборки $x^n = (x_1, \dots, x_n), x_i \in R, y^m = (y_1, \dots, y_m), y_i \in R$

Обозначим через μ_1 и μ_2 математическое ожидание выборок x^n и y^n .

Дополнительное предположение: выборки x^n и y^n являются нормальными

Нулевая гипотеза $H_0 : \mu_1 = \mu_2$

Альтернативные гипотезы:

1. $H_1 : \mu_1 \neq \mu_2$ (two-sided)
2. $H'_1 : \mu_1 > \mu_2$ (greater)
3. $H''_1 : \mu_1 < \mu_2$ (less)

Будем сравнивать математические ожидания выборок $data_1$ и $data_2$

8.2.1 Доверительный уровень 0.9

	T	dof	alternative	p-val	CI90%	cohen-d	BF10	power
T-test	-3.603357	168.143054	two-sided	0.000413	$[-1.889353, -0.700563]$	0.41842	58.465	0.951028

	T	dof	alternative	p-val	CI90%	cohen-d	BF10	power
T-test	-3.603357	168.143054	greater	0.999793	$[-1.757333, \infty)$	0.41842	0.009	7.112×10^{-8}

	T	dof	alternative	p-val	CI90%	cohen-d	BF10	power
T-test	-3.603357	168.143054	less	0.000207	$(-\infty, -0.832583]$	0.41842	116.93	0.975729

8.2.2 Доверительный уровень 0.95

	T	dof	alternative	p-val	CI95%	cohen-d	BF10	power
T-test	-3.603357	168.143054	two-sided	0.000413	$[-2.0, -0.59]$	0.41842	58.465	0.951028

	T	dof	alternative	p-val	CI95%	cohen-d	BF10	power
T-test	-3.603357	168.143054	greater	0.999793	$[-1.89, \infty)$	0.41842	0.009	7.112×10^{-8}

	T	dof	alternative	p-val	CI95%	cohen-d	BF10	power
T-test	-3.603357	168.143054	less	0.000207	$(-\infty, -0.7]$	0.41842	116.93	0.975729

8.2.3 Доверительный уровень 0.99

	T	dof	alternative	p-val	CI99%	cohen-d	BF10	power
T-test	-3.603357	168.143054	two-sided	0.000413	$[-2.231270, -0.358647]$	0.41842	58.465	0.951028

	T	dof	alternative	p-val	CI99%	cohen-d	BF10	power
T-test	-3.603357	168.143054	greater	0.999793	$[-2.139034, \infty)$	0.41842	0.009	7.112×10^{-8}

	T	dof	alternative	p-val	CI99%	cohen-d	BF10	power
T-test	-3.603357	168.143054	less	0.000207	$(-\infty, -0.450882]$	0.41842	116.93	0.975729

Исходя из данных можем сделать вывод, что математическое ожидание первой выборки меньше, чем второй

Выводы

Критерий Стьюдента используется для сравнения средних значений двух групп, чтобы определить, являются ли различия между ними статистически значимыми. Как мы выяснили, существует два вида тестов:

- Двусторонний тест: проверяет, отличаются ли средние значения групп в любом направлении.
- Односторонний тест: проверяет, превышает ли среднее значение одной группы среднее значение другой (или наоборот).

Он эффективен для анализа данных, где выборки соответствуют нормальному распределению, и используется в исследованиях для проверки гипотез.

8.3 Ранговый критерий Уилкоксона-Манна-Уитни

Пусть даны две независимые выборки $x^n = (x_1, \dots, x_n), x_i \in R, y^m = (y_1, \dots, y_m), y_i \in R$

Обозначим через μ_1 и μ_2 математическое ожидание выборок x^n и y^n .

Дополнительное предположение: выборки x^n и y^n являются нормальными

Нулевая гипотеза $H_0 : \mu_1 = \mu_2$

Альтернативные гипотезы:

1. $H_1 : \mu_1 \neq \mu_2$ (two-sided)
2. $H'_1 : \mu_1 > \mu_2$ (greater)
3. $H''_1 : \mu_1 < \mu_2$ (less)

Сравним среднюю температуру при высоком и низком риске

1. Среднее при низком - 37.2
2. Среднее при высоком - 39

`MannwhitneyUResult(statistic=4366.5, pvalue=8.666e-69)`

`MannwhitneyUResult(statistic=4366.5, pvalue=1)`

`MannwhitneyUResult(statistic=4366.5, pvalue=4.333e-69)`

То есть среднее значение температуры при высоком риске выше

8.4 Проверка гипотез об однородности дисперсий

8.4.1 Критерий Фишера

Пусть даны две независимые выборки $x^n = (x_1, \dots, x_n), x_i \in R, y^m = (y_1, \dots, y_m), y_i \in R$

Обозначим через σ_1 и σ_2 дисперсии выборок x^n и y^n .

Дополнительное предположение: выборки x^n и y^n являются нормальными

Нулевая гипотеза $H_0 : \sigma_1 = \sigma_2$

Альтернативные гипотезы:

1. $H_1 : \sigma_1 \neq \sigma_2$ (two-sided)
2. $H'_1 : \sigma_1 > \sigma_2$ (greater)
3. $H''_1 : \sigma_1 < \sigma_2$ (less)

Статистика критерия Фишера: $F = \frac{s_1^2}{s_2^2}$, где s_1^2, s_2^2 - выборочные оценки дисперсий. Статистика F имеет распределение Фишера с $n - 1$ и $m - 1$ степенями свободы. Обычно в числителе ставится большая из двух сравниваемых дисперсий

Так как критерий требует нормальности, а в моем датасете нормально распределенных колонок нет, сгенерируем данные вручную

1. `data_1`: математическое ожидание $\mu_1 = 0$, среднеквадратическое отклонение $\sigma_1 = 3$, количество элементов в выборке $n_1 = 100$
2. `data_2`: математическое ожидание $\mu_2 = 1$, среднеквадратическое отклонение $\sigma_1 = 3$, количество элементов в выборке $n_2 = 300$

p-value для `data_1` и `data_2`

1. 0.3531 - two-sided
2. 0.1765 - greater
3. 0.8235 - less

Из этих значений может сделать вывод, что дисперсии равны

8.4.2 Критерий Левене

Пусть даны две независимые выборки $x^n = (x_1, \dots, x_n), x_i \in R, y^m = (y_1, \dots, y_m), y_i \in R$

Обозначим через σ_1 и σ_2 дисперсии выборок x^n и y^n .

Нулевая гипотеза $H_0 : \sigma_1 = \sigma_2$

Альтернативная гипотеза:

$H_1 : \sigma_1 \neq \sigma_2$ (two-sided)

Сравним дисперсию температуры при высоком и низком риске

p-value теста: 2.61e-18 поэтому гипотезу о равенстве дисперсий отвергаем

8.4.3 Критерий Бартлетта

Пусть даны две независимые выборки $x^n = (x_1, \dots, x_n), x_i \in R, y^m = (y_1, \dots, y_m), y_i \in R$

Обозначим через σ_1 и σ_2 дисперсии выборок x^n и y^n .

Дополнительное предположение: выборки x^n и y^n являются нормальными

Нулевая гипотеза $H_0 : \sigma_1 = \sigma_2$

Альтернативная гипотеза:

$H_1 : \sigma_1 \neq \sigma_2$ (two-sided)

Так как критерий требует нормальности, а в моем датасете нормально распределенных колонок нет, сгенерируем данные вручную

1. *data_1*: математическое ожидание $\mu_1 = 0$, среднеквадратическое отклонение $\sigma_1 = 3$, количество элементов в выборке $n_1 = 100$
2. *data_2*: математическое ожидание $\mu_2 = 1$, среднеквадратическое отклонение $\sigma_1 = 3$, количество элементов в выборке $n_2 = 300$

p-value для *data_1* и *data_2* - 0.6, поэтому нулевая гипотеза не отвергается

8.4.4 Критерий Флигнера-Килина

Пусть даны две независимые выборки $x^n = (x_1, \dots, x_n), x_i \in R, y^m = (y_1, \dots, y_m), y_i \in R$

Обозначим через σ_1 и σ_2 дисперсии выборок x^n и y^n .

Нулевая гипотеза $H_0 : \sigma_1 = \sigma_2$

Альтернативная гипотеза:

$H_1 : \sigma_1 \neq \sigma_2$ (two-sided)

Сравним дисперсию температуры при высоком и низком риске

p-value - 2.55e-17, поэтому нулевая гипотеза отвергается

9 Исследовать корреляционные взаимосвязи в данных с помощью коэффициентов корреляции Пирсона, Спирмена и Кендалла.

9.1 Коэффициент корреляции Пирсона

Пусть даны две независимые выборки $x^n = (x_1, \dots, x_n), x_i \in R, y^m = (y_1, \dots, y_m), y_i \in R$. Коэффициент корреляции Пирсона рассчитывается по формуле:

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{\text{cov}(x, y)}{s_x s_y}$$

где $\bar{x}, \bar{y}$ — выборочные средние, s_x^2, s_y^2 — выборочные дисперсии, $r_{xy} \in [-1, 1]$.

Коэффициент корреляции Пирсона называют также теснотой линейной связи:

- $|r_{xy}| = 1$ — линейно зависимы,
- $r_{xy} = 0$ — линейно независимы.

Посмотрим на степень линейной связи между Heart_Rate и Temperature

pvalue=6.99e-93, то есть есть статистически значимая линейная зависимость между данными

9.2 Коэффициент корреляции Спирмена

Коэффициент корреляции Спирмена — мера монотонной связи между случайными величинами. Корреляция Спирмена является ранговой, то есть для оценки силы связи используются не численные значения, а соответствующие им ранги. Коэффициент инвариантен по отношению к любому монотонному преобразованию шкалы измерения

Даны две выборки $x = (x_1, \dots, x_n), y = (y_1, \dots, y_n)$.

Коэффициент корреляции Спирмена вычисляется по формуле:

$$\rho = 1 - \frac{6}{n(n-1)(n+1)} \sum_{i=1}^n (R_i - S_i)^2,$$

где R_i — ранг наблюдения x_i в ряду x , S_i — ранг наблюдения y_i в ряду y .

Коэффициент ρ принимает значения из отрезка $[-1; 1]$. Равенство $\rho = 1$ указывает на строгую монотонную возрастающую зависимость, а $\rho = -1$ — на строгую монотонную убывающую зависимость.

Вычислим коэффициент корреляции между Systolic_Rate и Temperature

pvalue = 1.15e-110, statistic = -0.63 — сильная отрицательная монотонная связь между данными

9.3 Коэффициент корреляции Кендалла

Коэффициент корреляции Кендалла — мера монотонной связи между случайными величинами. Корреляция Кендалла является ранговой, то есть для оценки силы связи используются не численные значения, а соответствующие им ранги. Коэффициент инвариантен по отношению к любому монотонному преобразованию шкалы измерения.

Заданы две выборки $x = (x_1, \dots, x_n), y = (y_1, \dots, y_n)$.

Коэффициент корреляции Кендалла вычисляется по формуле:

$$\tau = 1 - \frac{4}{n(n-1)} R, \quad R = \sum_{i=1}^{n-1} \sum_{j=i+1}^n [(x_i < x_j) \neq (y_i < y_j)],$$

где R — количество инверсий, образованных величинами y_i , расположенными в порядке возрастания соответствующих x_i .

Коэффициент τ принимает значения из отрезка $[-1; 1]$. Равенство $\tau = 1$ указывает на строгую прямую монотонную зависимость, а $\tau = -1$ на обратную.

Исследуем на монотонную связь колонки Respiratory_Rate Oxygen_Saturation

statistic = -0.48, pvalue = 2.24e-100 — говорит о сильной отрицательной монотонной зависимости

10 Продемонстрировать использование методов хи-квадрат, точного теста Фишера, теста МакНемара, КохранаМантеля-Хензеля.

10.1 Метод хи-квадрат

Метод χ^2 (хи-квадрат) — статистический метод для проверки независимости двух категориальных переменных в таблице сопряженности $k \times l$.

Пусть A — категориальная переменная, принимающая n значений $a_1, a_2, \dots, a_n$, а B — категориальная переменная, принимающая k значений $b_1, b_2, \dots, b_k$.

	$A = a_1$	$A = a_2$	$\dots$	$A = a_n$
$B = b_1$	f_{11}	f_{12}	$\dots$	f_{1n}
$B = b_2$	f_{21}	f_{22}	$\dots$	f_{2n}
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$
$B = b_k$	f_{k1}	f_{k2}	$\dots$	f_{kn}

Нулевая гипотеза H_0 : переменные A и B независимы.

Статистика хи-квадрат вычисляется по формуле:

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^n \frac{(O_{ij} - E_{ij})^2}{E_{ij}},$$

где $O_{ij} = f_{ij}$ — наблюдаемая частота в ячейке (i, j) , а E_{ij} — ожидаемая частота при условии независимости:

$$E_{ij} = \frac{(\text{сумма по строке } i) \times (\text{сумма по столбцу } j)}{N},$$

где N — общее количество наблюдений.

Если вычисленное значение χ^2 превышает критическое значение для заданного уровня значимости α и числа степеней свободы $(k-1)(n-1)$, то гипотеза H_0 отвергается.

Выясним, существует ли зависимость между колонками O2_Scale и On_Oxygen

Построим таблицу сопряженности

	On Oxygen	O2 Scale
1	673	203
2	53	71

Теперь посмотрим, что выдаст код

Группа	On Oxygen	O2 Scale
1	635.976	240.024
2	90.024	33.976

Значение p-value = 3.93e-15, что говорит о статистически значимой зависимости

10.2 Точный тест Фишера

Точный тест Фишера — статистический метод для проверки независимости двух категориальных переменных в таблице сопряженности 2×2 , особенно эффективный при малых выборках.

Пусть A, B — две категориальные переменные, принимающие два значения: a_1, a_2 и b_1, b_2 соответственно.

	$A = a_1$	$A = a_2$
$B = b_1$	a	b
$B = b_2$	c	d

Нулевая гипотеза H_0 : переменные A и B независимы.

Альтернативная гипотеза H_1 : между переменными A и B существует статистически значимая зависимость.

Точная вероятность получения наблюдаемой таблицы (или более крайних) при условии независимости вычисляется по формуле:

$$P = \frac{(a+b)! \cdot (c+d)! \cdot (a+c)! \cdot (b+d)!}{a! \cdot b! \cdot c! \cdot d! \cdot n!}$$

Проверим еще раз, существует ли зависимость между O2_Scale и On_Oxygen

p-value = 5.94e-14, что говорит о статистически значимой зависимости

10.3 Тест МакНемара

Рассмотренный выше критерий хи-квадрат для анализа таблиц сопряженности размером 2×2 применим только в отношении независимых наблюдений. Если же учет какого-либо бинарного признака выполняется, например, на одних и тех же испытуемых, то вместо критерия хи-квадрат следует использовать **критерий Мак-Немара**. Он особенно полезен при анализе изменений в дихотомических переменных до и после воздействия или лечения.

	После: положительный	После: отрицательный	Итого
До: положительный	a	b	$a + b$
До: отрицательный	c	d	$c + d$
Итого	$a + c$	$b + d$	n

Обозначения:

- a : количество объектов с положительным результатом до и после воздействия;
- b : количество объектов с положительным результатом до и отрицательным после;
- c : количество объектов с отрицательным результатом до и положительным после;
- d : количество объектов с отрицательным результатом до и после.

Гипотезы:

- Нулевая гипотеза (H_0): пропорции положительных и отрицательных изменений равны, то есть $b = c$.
- Альтернативная гипотеза (H_1): пропорции положительных и отрицательных изменений различаются, то есть $b \neq c$.

Так как в моем датасете нет 'парных' данных, я сгенерировал

```
before = np.random.choice([0, 1], 1000, p=[0.7, 0.3])
after_1 = np.random.choice([0, 1], 1000, p=[0.6, 0.4])
```

col	0	1
0	418	298
1	166	118

p-value = 9.24e-10, то есть есть статистически значимая разница между before и after

10.4 Тест Кохрана-Мантеля-Хензеля

Тест Кохрана–Мантеля–Хензеля (КМХ) предназначен для анализа связи между двумя категориальными переменными при контроле влияния третьей категориальной переменной. Для этого создается K таблиц сопряженности 2×2 , где K — количество значений в третьей категориальной переменной.

Нулевая гипотеза, проверяемая при помощи КМХ-критерия, заключается в том, что между двумя анализируемыми качественными признаками нет никакой связи.

Посмотрим на колонки O2_Scale и On_Oxygen относительно колонки Consciousness

Составим таблицы сопряженности

A:		1	2
	0	643	51
	1	165	55

C:		1	2
	0	2	0
	1	3	2

P:		1	2
	0	4	0
	1	11	5

U:		1	2
	0	11	1
	1	10	4

V:		1	2
	0	13	1
	1	14	5

p-value = 5.98e-14, значит связь между O2_Scale и On_Oxygen есть

11 Проверить наличие мультиколлинеарности в данных с помощью корреляционной матрицы и фактора инфляции дисперсии.

Мультиколлинеарность — это явление, при котором одна из входных переменных статистической модели (например, множественной линейной регрессии) линейно зависит от других входных переменных, т.е. между ними наблюдается сильная корреляция. В этой ситуации оценки коэффициентов (параметров) модели могут случайно и значительно изменяться даже при небольших изменениях в исходных данных, т.е. решение становится неустойчивым.

Существует множество методов борьбы с мультиколлинеарностью, на своих датасетах я воспользуюсь первыми двумя из списка ниже:


1. Анализ корреляционной матрицы.
2. Фактор инфляции дисперсии (Variance Inflation Factor, VIF).
3. PCA (Principal Component Analysis): преобразование исходных переменных в набор независимых компонентов.
4. Регуляризация (например, Ridge или Lasso регрессия).

11.1 Корреляционная матрица

Корреляционная матрица (матрица корреляций) — это квадратная таблица, заголовками строк и столбцов которой являются обрабатываемые переменные, а на пересечении строк и столбцов выводятся коэффициенты корреляции для соответствующей пары признаков.

Корреляционная матрица обладает следующими свойствами:

1. На главной диагонали находятся коэффициенты корреляции, равные единице.
2. Матрица симметрична относительно главной диагонали.



Выводы: Можно проследить закономерности для каждой переменной, ее связи с другой. Например, уровень риска отрицательно зависит от сердцебиения

11.2 Фактор инфляции дисперсии

В задаче восстановления регрессии фактор инфляции дисперсии (VIF) — мера мультиколлинеарности. Он позволяет оценить увеличение дисперсии заданного коэффициента регрессии, происходящее из-за высокой корреляции данных.

Пусть задана выборка $D = \{y_i, x_i\}_{i=1}^n$ откликов и признаков. Рассматривается множество линейных регрессионных моделей вида:

$$y_i = \sum_{j=1}^m w_j x_{ij} + \epsilon_i, \quad i = 1, \dots, n$$

Предполагается, что вектор регрессионных невязок имеет нулевое математическое ожидание и дисперсию σ^2 . В этом случае дисперсия $\hat{w}_j$:

$$D\hat{w}_j = \frac{\sigma^2}{(n-1)Dx_j \cdot (1 - R_j^2)}$$

Первая дробь связана с дисперсией невязок и дисперсией векторов признаков. Вторая — фактор инфляции дисперсии, связанный с корреляцией данного признака с другими:

$$VIF_j = \frac{1}{1 - R_j^2}$$

где R_j^2 — коэффициент детерминации j -го признака относительно остальных:

$$R_j^2 = 1 - \frac{\sum_{i=1}^n (x_{ij} - \hat{x}_{ij})^2}{\sum_{i=1}^n (x_{ij} - \bar{x}_{ij})^2}$$

Равенство единице фактора инфляции дисперсии говорит об ортогональности вектора значений признака остальным. Если значение VIF_j велико, то $1 - R_j^2$ мало, то есть R_j^2 близко к 1. Большие значения фактора инфляции дисперсии соответствуют почти линейной зависимости j -го столбца от остальных. Высокие значения VIF указывают на потенциальные проблемы с мультиколлинеарностью. Как правило, значение VIF выше 5 требует внимания, а выше 10 — серьезного рассмотрения изменений в модели.

Для моего датасета

Признак	VIF
Respiratory_Rate	2.515955
Oxygen_Saturation	2.079750
O2_Scale	1.143735
Systolic_BP	2.469161
Heart_Rate	2.497943
Temperature	1.931664
Consciousness	1.162644
On_Oxygen	1.386430
Risk_Level	2.679308

Выводы: показатели VIF низкие, поэтому мультиколлинеарности нет

12 Исследовать зависимости в данных с помощью дисперсионного анализа.

Дисперсионный анализ (ANOVA) — это статистический метод, который используется для сравнения средних значений двух или более выборок. Он позволяет определить, различаются ли средние значения между группами, или же различия случайны.

12.1 Однофакторный дисперсионный анализ (one-way ANOVA)

Однофакторный ANOVA (однофакторный дисперсионный анализ) — это метод статистического анализа данных, который используется для определения наличия статистически значимых различий между двумя или более группами по одной независимой переменной.

Пусть A — категориальная переменная (фактор) с k уровнями и пусть $x^1 = (x_{11}, \dots, x_{1n}), \dots, x^k = (x_{k1}, \dots, x_{kn})$ — подвыборки выборки x , $\mu_1, \dots, \mu_k$ — математические ожидания подвыборок.

Нулевая гипотеза $H_0 : \mu_1 = \mu_2 = \dots = \mu_k$

Альтернативная гипотеза: не все средние равны.

Дополнительные предположения для однофакторного ANOVA:

1. **Независимость наблюдений:** данные в каждой группе должны быть независимыми друг от друга.
2. **Нормальность распределения:** распределение зависимой переменной в каждой группе должно быть близким к нормальному.
3. **Гомогенность дисперсий:** дисперсии зависимой переменной в разных группах должны быть примерно равными.

В моем датасете нет нормально распределенных данных, поэтому сгенерируем 3 группы с нормальным распределением:

- group1: $\mu = 0$, $\sigma = 1$, $n = 100$
- group2: $\mu = 5$, $\sigma = 1$, $n = 100$
- group3: $\mu = 10$, $\sigma = 1$, $n = 100$

Далее проводим однофакторный анализ:

F-статистика = 2505, p-value = 1.17e-186, т.е. мы не можем принять гипотезу о равенстве средних в группах

Выводы: для применения однофакторного дисперсионного анализа необходимо проверить независимость наблюдений, нормальность распределения зависимой переменной и гомогенность дисперсий зависимой переменной по группам.

12.2 Двухфакторный дисперсионный анализ (two-way ANOVA)

Двухфакторный дисперсионный анализ используется для оценки влияния двух независимых факторов на зависимую переменную, а также для анализа взаимодействия между этими факторами.

Посмотрим на частоту дыхания в зависимости от нахождения на кислороде и уровня сознания

Таблица 2: Результаты двухфакторного дисперсионного анализа для Respiratory_Rate

	Sum Sq	df	F	PR(>F)
On_Oxygen	3455.84	1	161.17	2.53×10^{-34}
Consciousness	1540.28	4	17.96	3.01×10^{-14}
On_Oxygen $\times$ Consciousness	245.43	4	2.86	0.0225
Residual	21227.25	990	NaN	NaN

Выводы: уровень влияния и нахождения на кислороде влияют на частоту дыхания

13 Подогнать регрессионные модели (в том числе, нелинейные) к данным, а также оценить качество подобной аппроксимации.

Я буду пытаться подогнать модель для анализа уровня риска по всем остальным переменным. Как критерий качества был использован ассигасу. Были построены следующие модели:

- Логистическая регрессия
- Линейная регрессия
- SMV

Результаты моделей

1. Логистическая регрессия — ассигасу = 0.976
2. Ridge регрессия — ассигасу = 0.736
3. SVM — ассигасу = 0.968

Выводы: логистическая регрессия лучше всего подходит в моей задаче для

14 Выводы

В процессе выполнения задания по курсу «Технологический практикум» я освоил применение инструментов статистического анализа данных на языках программирования R и Python.

Для анализа данных мной были использованы ключевые статистические методы и техники:

- **Визуализация данных:** построены графики `cdplot`, `dotchart`, `boxplot` и `stripchart`, что позволило наглядно представить распределение и вариативность данных.
- **Выявление выбросов:** применены критерии Граббеа и Q-тест Диксона для обнаружения аномальных значений в выборках.
- **Исследование нормальности распределения:** проанализированы свойства нормально распределённых выборок с помощью графиков эмпирических функций распределения, квантилей и метода огибающих, а также проведены стандартные процедуры проверки гипотез о нормальности.
- **Аппроксимация распределений:** выполнена оценка плотности распределения данных с помощью ядерных оценок, что позволило более точно охарактеризовать поведение случайных величин.
- **Обработка пропусков:** изучены и применены инструменты заполнения пропусков в данных, обеспечивающие корректный анализ даже при неполноте исходной информации.

Кроме того, я научился формулировать и проверять статистические гипотезы, используя следующие техники:

- **Параметрические и непараметрические тесты:** критерии Стьюдента, Уилкоксона-Манна-Уитни, Фишера и другие.
- **Корреляционный анализ:** исследованы взаимосвязи между переменными с помощью коэффициентов корреляции Пирсона, Спирмена и Кендалла.
- **Критерии независимости:** применены методы хи-квадрат, Фишера, МакНемара и Кохрана-Мантеля-Хензеля для проверки независимости распределений.

Важным этапом работы стала проверка наличия мультиколлинеарности в данных с использованием корреляционной матрицы и фактора инфляции дисперсии (VIF). Также был проведён дисперсионный анализ (однофакторный и двухфакторный) и подгонка регрессионных моделей под имеющиеся данные, что позволило выявить основные влияющие факторы и построить предсказательные модели.

Все применённые методы были успешно реализованы на выбранных мной датасетах, что позволило глубоко проанализировать представленные данные и сделать обоснованные выводы. В результате выполнения данного задания я значительно повысил свои навыки в области статистического анализа данных и их интерпретации.

Кроме того, результаты, полученные с использованием языков программирования Python и R, оказались практически идентичными, что подтверждает возможность применения обоих языков программирования для статистического анализа данных.

15 Литература

1. Брюс П., Брюс Э., Гедек П. *Практическая статистика для специалистов Data Science*. – 2-е изд., перераб. и доп. – СПб.: БХВ-Петербург, 2021. – 352 с.
2. Мастицкий С.Э., Шитиков В.К. *Статистический анализ и визуализация данных с помощью R*. – М.: ДМК Пресс, 2015. – 496 с.
3. Нильсен Э. *Практический анализ временных рядов: прогнозирование со статистикой и машинное обучение*. – СПб.: ООО «Диалектика», 2021. – 544 с.